



Consultoría en Data Science & AI

Sistema de Recomendación Personalizado para E-commerce de Retail

Data Science • SoyHenry • 2026

Identidad del Equipo

Campo	Detalle
Nombre del equipo consultor	Nexus Data Co.
Correo institucional	nexusdataco.equipo@gmail.com
Misión	Transformar datos en decisiones de negocio. Somos un equipo de consultores especializados en soluciones de Data Science aplicadas al e-commerce, con foco en personalización, escalabilidad y valor medible.

Integrantes

#	Apellido, Nombre	Rol
1	Leila, Abduca.	ML Engineer.
2	Alexis Jacquet.	MLOps Engineer.
3	Dody Salim Dueñas Remache.	Data Analyst.
4	Wilson Henry Bello Velandia.	ML Engineer.

1. Caso de Negocio

Industria	Comercio y Consumo — E-commerce de Retail
Campo	Contenido
Contexto y definición del problema de negocio	Un retailer online enfrenta una baja tasa de conversión (~0.8% de visitas terminan en compra) como consecuencia de una experiencia de navegación genérica que no considera el historial ni las preferencias individuales de cada usuario. El catálogo es amplio pero invisible: la mayor parte de los productos nunca alcanza al segmento de usuarios con mayor probabilidad de compra. Problema de negocio: El sistema actual no personaliza la experiencia del usuario, lo que genera altas tasas de abandono y sub-aprovechamiento del catálogo de productos.
Objetivo principal	Desarrollar un sistema de recomendación personalizado que, a partir del historial de interacciones de los usuarios (vistas, carritos y transacciones), sugiera productos relevantes para cada sesión, con el fin de incrementar la tasa de conversión y el valor promedio por sesión de manera medible.

Campo	Contenido
KPI Principal	Tasa de conversión del sistema de recomendación (% de usuarios que concretan una compra a partir de un ítem recomendado)
KPI Secundario	Cobertura del catálogo recomendado (% de productos únicos que el sistema recomienda al menos una vez en un período dado)

2. Fuentes de Datos

Campo	Detalle
Fuente de datos	Retailrocket Recommender System Dataset https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset
Tipo de datos	Datos reales de comportamiento de usuarios en un sitio de e-commerce, publicados de forma abierta en Kaggle. Los valores están hasheados por razones de confidencialidad, lo que constituye un problema de calidad real a resolver.
Descripción del dataset	El dataset consta de 3 archivos interrelacionados: • events.csv: 2.756.101 eventos de comportamiento generados por 1.407.580 visitantes únicos durante 4,5 meses. Variables: timestamp, visitorid, event (view / addtocart / transaction), itemid, transactionid. • item_properties_part1.csv y item_properties_part2.csv: Propiedades de los ítems con valores hasheados (incluye texto), que permiten construir perfiles de productos. • category_tree.csv: Jerarquía de categorías del catálogo.
Problemas de calidad esperados	• Valores hasheados: los atributos de ítems no son legibles directamente, requieren tratamiento. • Sesgo de popularidad: distribución long-tail donde unos pocos ítems concentran la mayoría de las interacciones. • Usuarios cold-start: muchos visitantes tienen solo 1 o 2 eventos registrados. • Duplicados y sesiones incompletas: eventos sin transactionid válido. • Desbalance extremo: 96.7% son views, 2.5% addtocart y solo 0.8% transacciones.
Justificación de la elección	Este dataset permite modelar el problema de negocio de manera directa: contiene interacciones explícitas en tres niveles de intención (ver, agregar al carrito, comprar), lo que habilita la construcción de un sistema de recomendación con feedback implícito realista. Su tamaño es representativo sin ser inmanejable para un equipo de 4 personas. La presencia de problemas de calidad reales (valores hasheados, cold-start, sesgo de popularidad) lo convierte en un escenario auténtico de ciencia de datos aplicada, alineado con los objetivos metodológicos del Proyecto Final de SoyHenry.

3. Plan o Estrategia de Análisis

Campo	Detalle
Tipo de recomendación	• Productos similares (ítem-a-ítem): dado un producto visualizado, recomendar ítems con perfil de interacción similar. • Ranking personalizado por usuario: lista de productos ordenada por probabilidad estimada de compra para cada visitante. • Recomendaciones para usuarios nuevos (cold-start): recomendaciones basadas en popularidad y categoría para visitantes sin historial suficiente.
Entrada del sistema	• Historial de eventos del usuario (views, addtocart, transactions) con sus timestamps. • Propiedades del ítem (categoría, atributos del producto). • Para nuevos usuarios: eventos de la sesión activa + categoría del ítem en foco.
Salida del sistema	• Lista de los Top-N ítems recomendados (N configurable, típicamente 5 o 10) ordenados por relevancia estimada para el usuario o contexto. • Confianza o score asociado a cada recomendación.
Modelos planificados	1. Baseline — Popularidad global (benchmark de referencia) 2. Collaborative Filtering basado en ítems (Item-CF) 3. Matrix Factorization con ALS (Alternating Least Squares) para feedback implícito 4. Content-Based Filtering usando propiedades textuales de los ítems (TF-IDF / embeddings) 5. Modelo híbrido (ensamble CF + Content-Based) para mitigar cold-start
Evaluación (nivel conceptual)	Se utilizarán métricas estándar de sistemas de recomendación: Precision@K, Recall@K y NDCG@K. Se comparará cada modelo contra el baseline de popularidad para cuantificar la mejora real.
Despliegue	• API REST con FastAPI: endpoint que recibe un visitorid y retorna Top-N recomendaciones en tiempo real. • Dashboard interactivo (Streamlit o Power BI) con KPIs del funnel de conversión, comparativa de modelos y simulador de recomendaciones. • Demo en vivo para la presentación final del proyecto.

4. Plan de Trabajo — Sprints Scrum

Sprint	Objetivo	Entregables clave
Sprint 1	Ingeniería de datos y EDA	Merge de archivos, limpieza de datos, análisis del funnel, visualizaciones, documentación inicial
Sprint 2	Modelos baseline y Collaborative Filtering	Modelo de popularidad, User-CF e Item-CF implementados y evaluados con métricas

Sprint	Objetivo	Entregables clave
Sprint 3	Matrix Factorization y Content-Based	ALS/SVD con feedback implícito, NLP en propiedades de ítems, comparativa de modelos
Sprint 4	Producto de datos y presentación	API REST funcional, dashboard, informe final, demo en vivo

Nexus Data Co. — nexusdataco.equipo@gmail.com